

DIPLOMADO IA APLICADA AL DISEÑO · UDD 2026 · UNIDAD 3

Clase 23 — Datos, sesgos y cómo aprende una IA

Martes 18 de agosto de 2026 · 18:30–21:00 hrs

Sesión 2 de 10 · Propuesta D

Apertura

Un modelo de IA es tan bueno, tan justo y tan limitado como los datos con los que fue entrenado. Esta clase entra al ingrediente base: **los datos**. Cómo aprende una IA, qué es un dataset, por qué los sesgos importan, y cómo detectar problemas antes de heredarlos ciegamente.

Es la segunda clase con Colab. Vamos a **ver** un dataset real, jugar con él, y detectar visualmente sesgos que después vas a poder aplicar a los datos de tu propio proyecto.

Resultado de aprendizaje

Al finalizar la clase el estudiante podrá:

1. **Explicar** el ciclo de aprendizaje de un modelo (ejemplos → ajuste → repetición).
2. **Identificar** tres tipos de sesgo (representación, medición, histórico) y ejemplos concretos.
3. **Explorar visualmente** un dataset en Colab: balance de clases, valores faltantes.
4. **Iniciar la “ficha de datos”** de su proyecto: qué datos existen, de dónde vienen, qué sesgos esperar.

Glosario clave

Término	Definición operativa
Dataset	Colección organizada de datos usada para entrenar un modelo.
Etiquetar (labeling)	Asignar categorías a los datos. Ejemplo: marcar imágenes como “gato” o “perro”.
Sesgo	Distorsión sistemática en los datos que el modelo aprende y amplifica.
Curación	Proceso de seleccionar, limpiar y organizar datos. Es donde entra el juicio humano.
Datasheet	Documento que acompaña a un dataset: quién lo hizo, cómo, para qué, con qué sesgos.
Balance de clases	Qué proporción tiene cada categoría en el dataset. Un desbalance grande = un modelo que aprende sesgado.

Bloque 1 (10 min): Cómo aprende una IA

El entrenamiento es este loop, repetido millones de veces:

1. Le muestras un ejemplo con la respuesta correcta.
2. El modelo hace su predicción.
3. Mides cuánto se equivocó (esto se llama "loss").
4. Ajustas ligeramente los parámetros para reducir el error.
5. Repites con otro ejemplo. Millones de veces.

Eso es todo. No hay magia. La sofisticación está en la escala (millones/billones de ejemplos) y en la arquitectura del modelo, pero el principio es simple: **enseñarle mediante ejemplos hasta que se equivoque poco.**

Punto crítico: si le enseñas con ejemplos malos, aprende mal. La IA no tiene un “filtro de sentido común” — copia y amplifica lo que ve.

Bloque 2 (10 min): De dónde salen los datos

Para un modelo grande (GPT, Claude, Gemini): - Casi todo internet: web abierta, libros escaneados, código de GitHub, foros, Wikipedia. - Millones de imágenes de Flickr, sitios web, redes sociales (LAION). - Videos de YouTube, transcripciones.

Consecuencias de esa procedencia: - **~60% del texto de entrenamiento está en inglés.** El español (todas sus variantes) es ~5%. Las lenguas chilenas originarias son prácticamente invisibles. - **Los sesgos culturales del norte global quedan cristalizados.** “CEO” produce mayoritariamente hombres blancos. - **Consentimiento y derechos:** la mayoría de las personas cuyo trabajo entrenó a estos modelos no lo autorizó explícitamente.

Para tu trabajo de diseño en Chile esto no es abstracto: cambia cómo se comportan las herramientas cuando les pides algo local.

Bloque 3 (10 min): Tres tipos de sesgo que vas a encontrar

Tipo	Cómo se ve	Ejemplo
Representación	Sub o sobrerrepresentación de grupos	Reconocimiento facial que falla con personas afrodescendientes porque el dataset es 80% caucásico (caso Buolamwini & Gebru, 2018).
Medición	El método de recolección distorsiona	Sistema entrenado con reportes de usuarios anglosajones que marca como “agresivo” el habla coloquial chilena.
Histórico	Los datos reflejan desigualdades del pasado	Modelo de recomendación de carreras que sugiere ingeniería a hombres, enfermería a mujeres, porque eso vio en datos históricos.

Lo que sí puedes hacer: documentar explícitamente los sesgos esperados, diversificar los datos, evaluar por subgrupos, incorporar voces afectadas en el diseño. **Lo que no puedes hacer:** “eliminar el sesgo” — eso es ingenuo. Puedes mitigarlo, no borrarlo.

Ejercicios prácticos (90 min)

Ejercicio 1 — Explorar un dataset real	25 min
Ejercicio 2 — Detectar un sesgo visual	25 min
Ejercicio 3 — Empezar la datasheet de tu proyecto	30 min
Ejercicio 4 — Subir avance al repo	10 min

Revisiones en salas (30 min)

Formato: salas breakout de 3-4 estudiantes.

Consigna

Cada estudiante (5-7 min):

1. Muestra su datasheet borrador.
2. Cuenta un sesgo que anticipó y cómo lo va a mitigar.
3. Recibe del grupo **una pregunta sobre el origen de sus datos** que no se haya hecho aún.

Cierre en plenario (5 min)

Preguntas guía del profesor:

- ¿Alguien encontró que sus datos son más problemáticos de lo que pensaba?
 - ¿Qué estrategias de mitigación aparecieron más de una vez?
 - ¿Alguien decidió cambiar el dataset después de esta discusión?
-

PREGUNTA ABIERTA DE CIERRE

“Si el dataset que heredas para tu proyecto ya está “sesgado” y no puedes cambiarlo — ¿es responsable del modelo, del cliente que te lo pasó, o de tú por usarlo? ¿Dónde queda tu agencia profesional en esa cadena de responsabilidades?”